

Detección Automatizada y Caracterización Geométrica de Grietas de Riesgo en Concreto mediante Procesamiento de Imágenes

Luis Antonio Sanchez

Sebastian Sabogal

Mateo Gutierrez Suarez

May 24, 2025

Abstract

La detección temprana y precisa de grietas en estructuras de concreto es crucial para la seguridad y el mantenimiento eficiente de infraestructuras. Los métodos tradicionales de inspección son a menudo costosos, subjetivos y requieren mucho tiempo. Este artículo presenta un pipeline de procesamiento de imágenes diseñado para la detección automatizada y la extracción de características geométricas de grietas en superficies de concreto. Se describe paso a paso la secuencia de operaciones, incluyendo preprocesamiento mediante interpolación bilineal, filtrado espacial con filtros de mediana y gaussiano, y transformaciones de intensidad como la corrección gamma y la umbralización adaptativa. La etapa final de detección de bordes se realiza utilizando el filtro Laplaciano, seguido de un análisis para cuantificar parámetros como longitud y ancho (en píxeles) de las grietas detectadas. Este trabajo utiliza imágenes del conjunto de datos SDNET2018 para ilustrar la aplicabilidad del pipeline. El objetivo es mejorar la objetividad y eficiencia en la identificación y caracterización inicial de grietas, sentando las bases para sistemas de monitoreo estructural más robustos.

Keywords: Detección de grietas, procesamiento de imágenes, concreto, inspección estructural, caracterización de grietas.

1 Introducción

El concreto es un material fundamental en la ingeniería civil, empleado extensivamente en la construcción de puentes, edificios, carreteras y otras infraestructuras críticas. La durabilidad y seguridad de estas estructuras pueden verse comprometidas por la aparición y propagación de grietas, las cuales pueden ser indicativas de degradación del material, sobrecargas estructurales o deficiencias en el diseño o construcción [1]. La detección temprana y precisa de estas grietas es, por lo tanto, esencial para la planificación de estrategias de mantenimiento preventivo, la evaluación de la integridad estructural y la prevención de fallos catastróficos que podrían acarrear pérdidas económicas y humanas significativas.

Los métodos convencionales de inspección de grietas se basan predominantemente en la evaluación visual realizada por inspectores calificados. Si bien la experiencia humana es invaluable, este enfoque presenta limitaciones considerables: es un proceso laborioso, costoso, especialmente en estructuras de gran envergadura o de difícil acceso, e inherentemente subjetivo, lo que puede llevar a inconsistencias en la detección y cuantificación del daño. Además, la exposición de los inspectores a entornos peligrosos es una preocupación constante. Otras técnicas, como el uso de sensores físicos (e.g., extensómetros, fibra óptica), pueden ofrecer mediciones precisas, pero su implementación a gran escala suele ser prohibitiva debido a los altos costos de instalación y mantenimiento.

En respuesta a estas limitaciones, ha habido un creciente interés en el desarrollo de sistemas automatizados para la detección de grietas, aprovechando los avances en el campo del procesamiento de imágenes y, más recientemente, del aprendizaje profundo. Estos enfoques ofrecen el potencial de realizar inspecciones de manera más rápida, objetiva, consistente y económica. Diversos estudios han explorado esta vía; por ejemplo, Drouyer (2020) desarrolló un detector de grietas "todo terreno" utilizando aprendizaje profundo, entrenado con bases de datos como SDNET2018, y demostró que la combinación de diversos conjuntos de datos mejora la robustez del modelo [1]. Lin, Y., et al. (2025) propusieron el uso de una Red Neuronal Ridgelet (RNN) optimizada mediante algoritmos de evolución humana para mejorar la clasificación de grietas en concreto [2]. Por su parte, Şermet, F., & Paçal, I. (2024) investigaron la aplicación de Vision Transformers (ViT) junto con Redes Neuronales Convolucionales (CNNs) para la detección de grietas en carreteras y muros, destacando el rendimiento de arquitecturas avanzadas [3].

El presente trabajo se centra en la descripción detallada de un pipeline de procesamiento de imágenes específicamente diseñado no solo para la detección de grietas en concreto, sino también para la extracción de características geométricas básicas de las mismas. Se describen las etapas de preprocesamiento, mejora de la imagen, detección de características (bordes) y post-procesamiento para la cuantificación de parámetros de las

grietas, utilizando como base el conjunto de datos SDNET2018 [4] para la contextualización. El objetivo es establecer una secuencia de operaciones fundamentada que permita una identificación clara y la extracción de información dimensional (en píxeles) de las grietas, sirviendo como un componente esencial para futuros sistemas de inspección y evaluación estructural.

2 Metodología

La metodología propuesta para la detección y caracterización de grietas en concreto se basa en un pipeline de procesamiento de imágenes secuencial, diseñado para transformar una imagen de entrada en una representación donde las grietas sean claramente identificables y medibles. A continuación, se describen los datos utilizados y cada una de las etapas del pipeline.

2.1 Descripción Completa de los Datos

Para el desarrollo y la ilustración de las técnicas de procesamiento de imágenes, se hace referencia al conjunto de datos **SDNET2018 (Structural Defect Network 2018)** [4]. Este es un conjunto de datos público y ampliamente utilizado en la comunidad de investigación para la detección de defectos en estructuras de concreto.

- **Fuente y Adquisición:** Las imágenes fueron capturadas por investigadores de la Universidad Estatal de Utah utilizando una cámara digital Nikon de 16 MP. Se fotografiaron diversas superficies de concreto en condiciones realistas.
- **Tipos de Superficies:** El dataset incluye imágenes de [4]:
 - Cubiertas de puentes (imágenes tomadas en el laboratorio SMASH).
 - Muros (fotografías del edificio Russell/Wanlass Performance Hall).
 - Pavimentos (imágenes de carreteras y aceras del campus universitario).
- **Características de las Imágenes:** Cada imagen original fue segmentada en sub-imágenes de 256×256 píxeles en formato JPEG. El conjunto totaliza más de 56,000 imágenes, incluyendo superficies con y sin grietas [4].
- **Desafíos Inherentes:** Las imágenes presentan una variedad de condiciones y artefactos que simulan desafíos del mundo real, tales como sombras, variaciones en la rugosidad superficial, presencia de escamas, manchas, bordes de objetos, agujeros y escombros de fondo [4]. Esta diversidad hace que SDNET2018 sea un buen banco de pruebas para la robustez de los algoritmos de detección.

2.2 Pipeline de Procesamiento de Imágenes

El pipeline de procesamiento propuesto consiste en una serie de etapas aplicadas secuencialmente a la imagen de entrada para mejorar la visibilidad de las grietas, facilitar su detección y extraer sus características geométricas. La secuencia general es la siguiente:

1. Imagen Original.
2. Preprocesamiento: Interpolación Bilineal.
3. Filtrado Espacial:
 - a. Filtro de Mediana.
 - b. Filtro Gaussiano.
4. Transformación de Intensidad:
 - a. Corrección Gamma.
 - b. Umbralización Adaptativa.
5. Detección de Bordes: Filtro Laplaciano.
6. **Post-procesamiento y Extracción de Características Geométricas.**
7. Imagen de Resultado con Grietas Resaltadas (y opcionalmente, caracterizadas).

Un diagrama esquemático del pipeline se muestra en la Figura 1.

Pipeline de Procesamiento de Imágenes - Grietas

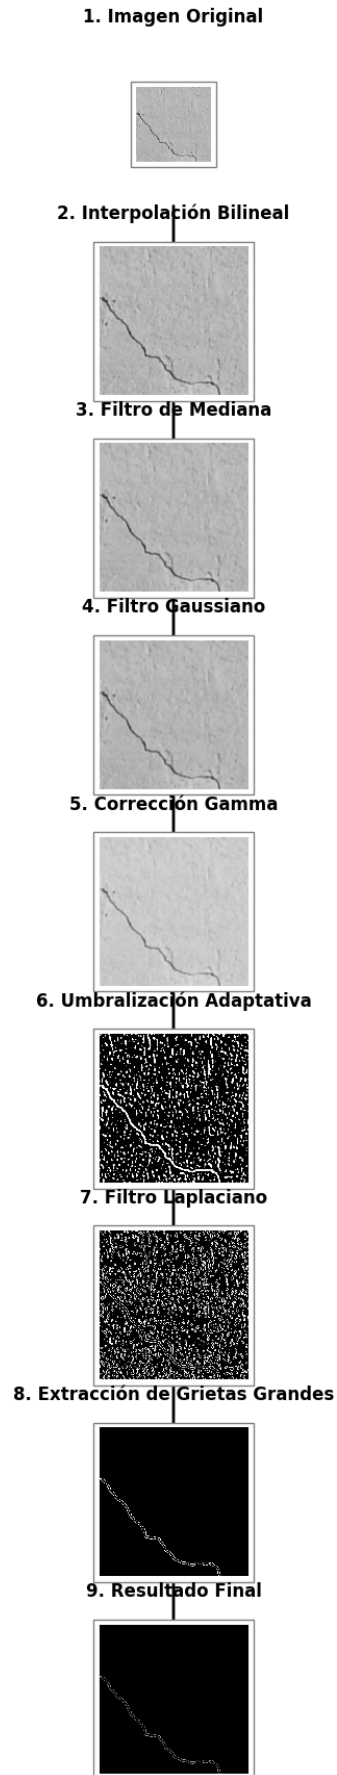


Figure 1: Diagrama del pipeline de procesamiento de imágenes propuesto para la detección y caracterización de grietas. Ilustra las etapas secuenciales del procesamiento, desde la imagen original hasta la extracción de características de las grietas detectadas.

2.3 Descripción de las Técnicas de Procesamiento Utilizadas en el Pipeline

A continuación, se detalla cada una de las técnicas empleadas en el pipeline:

2.3.1 Interpolación Bilineal

- **Descripción:** Esta técnica se utiliza para el remuestreo de imágenes, permitiendo cambiar su tamaño o realizar transformaciones geométricas. Calcula el valor de un nuevo píxel como un promedio ponderado de los cuatro píxeles vecinos más cercanos en la imagen original. La ponderación se basa en la distancia del nuevo píxel a sus vecinos.
- **Justificación en el Pipeline:** En la etapa de preprocesamiento, la interpolación bilineal se aplica para asegurar una resolución de imagen consistente o para escalar las imágenes si fuera necesario, sin introducir los artefactos de bloque que pueden surgir con métodos más simples como la interpolación del vecino más cercano. Ofrece un buen equilibrio entre calidad de imagen y costo computacional [5].

2.3.2 Filtro de Mediana

- **Descripción:** Es un filtro no lineal que reemplaza el valor de cada píxel por la mediana de los valores de intensidad en una vecindad definida alrededor de ese píxel.
- **Justificación en el Pipeline:** Se utiliza principalmente para la reducción de ruido impulsivo (sal y pimienta) en la imagen. Una ventaja clave del filtro de mediana es su capacidad para preservar los bordes mientras elimina el ruido, lo cual es crucial para no difuminar los contornos de las grietas [5].

2.3.3 Filtro Gaussiano

- **Descripción:** Es un filtro lineal que utiliza una función gaussiana como su kernel de convolución. Produce un efecto de suavizado en la imagen.
- **Justificación en el Pipeline:** Se aplica para suavizar la imagen y reducir el ruido de alta frecuencia (como el ruido gaussiano). Este suavizado puede ayudar a mejorar el rendimiento de las etapas posteriores, como la segmentación o la detección de bordes, al hacer que las estructuras de interés (grietas) sean más prominentes en relación con las texturas finas o el ruido residual [5].

2.3.4 Corrección Gamma

- **Descripción:** Es una transformación no lineal de la intensidad de los píxeles, definida por la relación

$$V_{\text{out}} = A \cdot V_{\text{in}}^{\gamma}$$

. Ajusta la luminancia general de una imagen.

- **Justificación en el Pipeline:** Se utiliza para ajustar los niveles de brillo y contraste. Es particularmente útil para imágenes que pueden estar subexpuestas o sobreexpuestas, ayudando a revelar detalles en áreas oscuras (grietas en sombra) o a atenuar zonas muy brillantes sin perder información crucial. La elección de

γ

permite controlar el grado de corrección [5].

2.3.5 Umbralización Adaptativa

- **Descripción:** A diferencia de la umbralización global que utiliza un único umbral para toda la imagen, la umbralización adaptativa calcula un umbral para cada píxel basándose en las características de intensidad de su vecindad local.
- **Justificación en el Pipeline:** Esta técnica es efectiva para segmentar objetos de fondo cuando hay variaciones significativas en las condiciones de iluminación a lo largo de la imagen. En el contexto de la detección de grietas, ayuda a poner de relieve las fisuras que podrían tener diferentes intensidades de píxel en distintas partes de la imagen, adaptándose a las condiciones lumínicas locales y mejorando la separación entre la grieta y el fondo de concreto [6].

2.3.6 Detección de Bordes (Filtro Laplaciano)

- **Descripción:** El operador Laplaciano es un operador diferencial de segundo orden que resalta las regiones de cambio rápido de intensidad en una imagen, es decir, los bordes. A menudo se utiliza en combinación con un suavizado previo (como el filtro Gaussiano, formando el Laplaciano de Gaussiana o LoG) para reducir su sensibilidad al ruido.
- **Justificación en el Pipeline:** Las grietas se manifiestan como discontinuidades o cambios abruptos en la intensidad de la imagen. El filtro Laplaciano (o LoG) es sensible a estos cambios y produce una imagen donde los bordes de las grietas se resaltan. El prefiltrado gaussiano implícito o explícito ayuda a obtener una detección de bordes más precisa y menos susceptible a errores debido al ruido presente en la imagen original o introducido en etapas previas [7].

2.3.7 Post-procesamiento y Extracción de Características Geométricas

- **Objetivo:** Una vez que las grietas han sido segmentadas (idealmente resultando en una imagen binaria tras la umbralización y detección de bordes), esta etapa se enfoca en refinar la segmentación y medir propiedades geométricas clave de cada grieta detectada.
- **Técnicas Aplicadas:**
 - *Análisis de Componentes Conectados (Blob Analysis):* Se emplea para identificar y etiquetar cada región de grieta segmentada como un objeto individual. Esto permite analizar cada grieta por separado. [8].
 - *Morfología Matemática (Opcional):* Operaciones como el cierre morfológico pueden aplicarse para rellenar pequeños huecos dentro de una grieta segmentada, o la apertura morfológica para eliminar pequeños artefactos o ruido que no correspondan a grietas significativas, mejorando la robustez de las mediciones posteriores. [8].
 - *Esqueletización:* Se aplica a cada grieta segmentada para obtener su representación como una línea de un píxel de ancho, conocida como esqueleto. Esto es fundamental para una estimación robusta de la longitud. [8].
- **Medición de Propiedades (en píxeles):**
 - *Longitud:* Estimada como la longitud del esqueleto de la grieta.
 - *Ancho Promedio/Máximo:* Puede estimarse analizando la transformada de distancia dentro de la región de la grieta segmentada o midiendo distancias perpendiculares al esqueleto en varios puntos.
 - *Área:* Calculada como el número total de píxeles que componen la grieta segmentada.
- **Justificación en el Pipeline:** La extracción de estas características geométricas transforma la detección cualitativa (presencia/ausencia de grieta) en una cuantificación inicial del daño. Aunque las mediciones son en píxeles, proporcionan una base para comparaciones relativas y pueden servir como entrada para análisis de severidad más avanzados. Herramientas como la biblioteca OpenCV facilitan la implementación de estas operaciones.

3 Resultados

3.1 Criterio de Detección de Grietas Peligrosas

El sistema desarrollado para la detección automática de grietas en superficies realiza un preprocesamiento de las imágenes y aplica una serie de técnicas de filtrado, realce y análisis morfológico para resaltar únicamente aquellas grietas que se consideran estructuralmente peligrosas.

3.2 Definición del Umbral de Peligrosidad

Considerando la resolución estándar de las imágenes utilizadas (256×256 píxeles), se ha establecido un umbral mínimo de área para los contornos detectados. Este umbral permite discriminar entre grietas significativas y ruido o imperfecciones menores.

Criterio aplicado:

- Sólo se consideran **grietas peligrosas** aquellas que presentan una **área mayor a 25 píxeles**.
- Los contornos que no superan este umbral son descartados automáticamente del análisis.

3.3 Justificación del Umbral de Área

En base a observaciones experimentales y a la resolución de las imágenes procesadas (256×256 píxeles), se ha definido como umbral mínimo una superficie de 25 píxeles para la detección de grietas peligrosas.

Asumiendo que cada imagen representa un área física de 10×10 cm, se obtiene que cada píxel abarca aproximadamente 0.0391 cm por lado. Por lo tanto, 25 píxeles representan un área aproximada de:

$$\text{Área} = 25 \times (0.0391 \text{ cm})^2 \approx 0.0383 \text{ cm}^2$$

Este valor corresponde a una fisura claramente visible a simple vista, que podría indicar el inicio de un deterioro estructural significativo en superficies de materiales de ingeniería.

3.4 Visualización y Salida del Proceso

El resultado del análisis es una imagen con las grietas peligrosas resaltadas en color rojo, sobre la imagen original convertida a formato RGB. Este procedimiento facilita la identificación visual rápida de los defectos más relevantes.

- Las imágenes procesadas se almacenan en la carpeta `output/` con el prefijo `resultado_`.
- El pipeline filtra automáticamente grietas pequeñas, sombras o artefactos que no representan una amenaza para la integridad estructural.

3.5 Ventajas del Enfoque

Este criterio permite:

1. Reducir el número de falsos positivos.
2. Enfocar el análisis en zonas de interés real.
3. Optimizar la revisión por parte de inspectores humanos o sistemas automatizados de evaluación estructural.

4 Discusión

El criterio de detección basado en un umbral mínimo de área para los contornos detectados demostró ser efectivo para discriminar grietas estructuralmente peligrosas de pequeñas imperfecciones o ruido visual. La elección de un área mínima de 25 píxeles, equivalente a aproximadamente 0.0383 cm^2 , se sustenta en la resolución estándar de las imágenes (256×256 píxeles) y en observaciones experimentales que correlacionan esta dimensión con grietas visibles a simple vista.

Este umbral contribuye a minimizar los falsos positivos, una problemática común en sistemas de detección automática, donde pequeños artefactos pueden ser erróneamente clasificados como defectos. Al filtrar automáticamente los contornos que no superan esta área, el sistema optimiza el enfoque hacia grietas que potencialmente representan un riesgo estructural real, facilitando la labor de inspección tanto humana como automatizada.

Sin embargo, es importante señalar que el umbral definido puede no ser universalmente aplicable a todas las situaciones o resoluciones de imagen. Por ejemplo, en superficies con mayor variabilidad en iluminación o texturas complejas, pequeñas grietas relevantes podrían ser descartadas si su área es inferior al límite establecido. Por ello, futuras mejoras podrían incluir un ajuste dinámico del umbral basado en características contextuales o el empleo de técnicas complementarias como análisis de profundidad o aprendizaje automático para validar la peligrosidad de grietas de menor tamaño.

Además, el sistema actual se limita a analizar imágenes con resolución fija y área física conocida, lo que limita su aplicabilidad en entornos donde las dimensiones reales pueden variar. Implementar mecanismos de calibración automática o incorporar datos adicionales, como escalas físicas o sensores, podría aumentar la precisión y versatilidad del sistema.

Finalmente, la visualización mediante resaltado en rojo de las grietas peligrosas sobre la imagen original es una herramienta valiosa para inspecciones rápidas y reportes visuales, mejorando la comprensión y toma de decisiones por parte de los técnicos.

En resumen, el enfoque adoptado ofrece un balance adecuado entre sensibilidad y precisión, aunque su rendimiento podría beneficiarse de adaptaciones y validaciones adicionales para aplicaciones más diversas.

5 Conclusiones

El sistema desarrollado para la detección automática de grietas peligrosas en superficies ha demostrado ser efectivo al implementar un umbral de área mínima para discriminar grietas significativas de pequeñas imperfecciones o ruido. El criterio establecido, con un valor de 25 píxeles (aproximadamente 0.0383 cm^2), permite focalizar el análisis en defectos que potencialmente comprometen la integridad estructural.

La aplicación de técnicas de preprocesamiento, filtrado y análisis morfológico garantiza que sólo las grietas relevantes sean resaltadas, reduciendo el número de falsos positivos y facilitando la inspección visual y automatizada. Además, la generación de imágenes de salida con las grietas peligrosas marcadas mejora la rapidez y claridad en la identificación de defectos.

No obstante, se reconoce la necesidad de adaptar o calibrar el umbral para diferentes resoluciones o condiciones de imagen, así como la posibilidad de integrar métodos adicionales para mejorar la detección de grietas pequeñas pero críticas.

En conclusión, el enfoque propuesto ofrece una solución práctica y eficiente para la detección de grietas peligrosas en superficies de ingeniería, contribuyendo a la mejora de los procesos de mantenimiento y control estructural.

References

- [1] S. Drouyer, "An 'All Terrain' Crack Detector obtained by Deep Learning on Available Databases," *Image Processing On Line*, vol. 10, pp. 282-301, 2020. DOI: [10.5201/ipol.2020.282](https://doi.org/10.5201/ipol.2020.282).
- [2] Y. Lin, et al., "Concrete Crack Detection using Ridgelet Neural Network optimized by Advanced Human Evolutionary Optimization," *Scientific Reports*, 2025 (artículo previsto). DOI: [10.1038/s41598-025-89250-3](https://doi.org/10.1038/s41598-025-89250-3).
- [3] F. Şermet and I. Paçal, "Deep Learning Approaches for Autonomous Crack Detection in Concrete Wall, Brick Deck and Pavement," *DUJE*, vol. 15, no. 2, pp. 503-513, 2024. DOI: [10.24012/dumf.1450640](https://doi.org/10.24012/dumf.1450640).
- [4] A. Sharma, "Structural Defects Network - Concrete Crack Images (SDNET2018) [Dataset]," Kaggle, 2018. [Online]. Available: <https://www.kaggle.com/datasets/aniruddhsharma/structural-defects-network-concrete-crack-images>.
- [5] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4th ed. Pearson, 2018.
- [6] D. Bradley and G. Roth, "Adaptive thresholding using the integral image," *Journal of Graphics Tools*, vol. 12, no. 2, 2007.
- [7] D. Marr and E. Hildreth, "Theory of edge detection," *Proceedings of the Royal Society of London. Series B. Biological Sciences*, vol. 207, no. 1167 1980.
- [8] Fabrizio, L. P. M. (2021). *Detección de grietas en la vía pública para prevenir las caídas*. Recuperado de <https://repositorio.unab.cl/items/c0b59d62-41d9-44e2-8c5c-095260dcec63>
- [9] Ministerio de Transporte de Colombia. (2013). *Manual de inspección y mantenimiento de puentes*. Bogotá: Instituto Nacional de Vías (INVIAS). Recuperado de <https://www.invias.gov.co/index.php/archivo-y-documentos/documentos-tecnicos/manuales-de-inspeccion-de-obras/976-manual-para-la-inspeccion-visual-de-puentes-y-pontones>